📄 **BRIEFING DO PROJETO INTEGRADOR**

Disciplina: Hands-On Fundamentos de Dados e Analytics
Módulo 1 – MBA em Engenharia de Dados – Universidade Presbiteriana Mackenzie
Mentoria: Prof. Gustavo Ferreira

---

1. IDENTIFICAÇÃO DO GRUPO

- **Nome do Projeto:** Raio-X do Vendedor: Diagnóstico 360° para vendedores de e-commerce (base Olist)
- **Setor de Atuação:** ☑ Varejo ☐ Saúde ☐ Finanças ☐ Logística ☐ Setor Público ☐ Outro: _____
- **Integrantes :**

Nome completo	**E-mail**	**LinkedIn**
Maria Laura [sobrenome]		
Giulia Santiago		
Luana Rodrigues		
Vinicius [sobrenome]		

---

2. DESCRIÇÃO DO PROBLEMA DE NEGÓCIO

2.1 Qual é o problema que vocês pretendem resolver?

Exemplo: “A empresa X está enfrentando uma alta taxa de cancelamento de clientes no primeiro mês de contrato.”

Vendedores autônomos e pequenos lojistas de marketplace tomam decisões de preço, frete e logística sem comparar o próprio desempenho com o dos melhores vendedores da sua categoria. Eles não sabem qual é a sua saúde real como e-commerce nem quais ações teriam maior impacto, e só percebem o problema quando a nota de avaliação já caiu. Pergunta central: para um vendedor que quer vender uma categoria a partir do seu estado, qual é o tamanho do mercado, quanto o frete pesa no preço e qual é o risco de o pedido atrasar e gerar avaliação ruim?

2.2 Qual é o impacto do problema para o negócio?

Exemplo: “A perda de clientes nos três primeiros meses impacta em até 35% da receita prevista no plano anual.”

Na base da Olist, cerca de 8% dos pedidos entregues chegam depois do prazo estimado, e esses pedidos recebem nota média de 2,57, contra 4,29 nos pedidos no prazo; 53% dos pedidos atrasados têm nota 1 ou 2, contra 9% dos pedidos no prazo. O frete mediano equivale a 23% do preço do item e é de 30% ou mais do preço em 37% dos itens, o que pressiona a margem. A maioria dos vendedores é pequena (mediana de 7 pedidos entre os vendedores com entregas) e, sem referência de mercado, tem pouca chance de corrigir o rumo antes de perder reputação e receita. Muitos negócios quebram justamente por falta de planejamento e de cultura data driven.

---

3. OBJETIVOS DO PROJETO

3.1 Objetivo Geral:

Exemplo: “Criar um modelo preditivo para identificar clientes com alta probabilidade de churn e propor ações de retenção.”

Desenvolver, a partir dos dados públicos da Olist, uma solução de dados ponta a ponta (pipeline em camadas, análises e Machine Learning) que gere automaticamente um Diagnóstico 360° para vendedores autônomos, comparando o vendedor com os melhores lojistas da mesma categoria e entregando a Nota de Saúde do E-commerce e as 3 ações prioritárias para ampliar o faturamento no mês seguinte.

3.2 Objetivos Específicos (mínimo 3):

- Integrar as 9 tabelas da Olist em um pipeline de dados nas camadas Bronze, Silver e Gold, com tratamento de qualidade e versionamento em Git.
- Construir indicadores por vendedor (receita, ticket, frete sobre preço, atraso, tempo de postagem, avaliações) e o benchmark dos melhores lojistas de cada categoria.
- Calcular a Nota de Saúde (0 a 100) e priorizar as 3 ações de maior impacto para cada vendedor.
- Desenvolver o Radar de Oportunidades por Categoria e Geografia: distância (Haversine) entre vendedor e comprador, mapa de calor logístico e análise de saturação.
- Treinar e validar o Motor Preditivo de Riscos Logísticos (Random Forest ou XGBoost), com termômetro de envio verde, amarelo e vermelho.
- Entregar um relatório executivo automatizado (PDF e/ou dashboard interativo) e documentar a solução no GitHub.

4. DADOS UTILIZADOS

4.1 Fonte de Dados:

Kaggle – Brazilian E-Commerce Public Dataset by Olist (9 tabelas CSV: orders, order_items, order_payments, order_reviews, customers, sellers, products, geolocation e product_category_name_translation).

4.2 Descrição da base:

- Número de registros: 119.143 linhas no DataFrame mestre (após unir as tabelas); tabelas originais: 99.441 pedidos, 112.650 itens, 99.224 avaliações, 3.095 vendedores, 32.951 produtos e 1.000.163 registros de geolocalização
- Número de atributos: 40 colunas no DataFrame mestre (as 9 tabelas somam 52 colunas originais)
- Período coberto: setembro de 2016 a outubro de 2018

4.3 Principais variáveis:

Nome	Tipo	Significado	Tratamento necessário?
order_id	Texto (chave)	Identificador do pedido; liga orders, itens, pagamentos e avaliações	☑ Sim
seller_id / customer_id	Texto (chave)	Identificadores do vendedor e do cliente	☑ Sim
price	Numérico	Preço do item	☑ Sim
freight_value	Numérico	Valor do frete cobrado	☑ Sim
order_purchase_timestamp e demais datas	Data/hora	Compra, aprovação, postagem, entrega real e entrega estimada	☑ Sim
delivery_time_days (derivada)	Numérico	Dias entre a compra e a entrega ao cliente	☑ Sim
delivery_delay_days (derivada)	Numérico	Entrega real menos estimada (negativo = entregue antes do prazo)	☑ Sim

Nome	Tipo	Significado	Tratamento necessário?
review_score	Numérico (1 a 5)	Nota de avaliação do cliente	☑ Sim
product_category_name	Categórico	Categoria do produto, traduzida para o inglês	☑ Sim
customer_state / seller_state	Categórico	UF do comprador e do vendedor; define a rota	☐ Não
lat / lng (geolocation)	Numérico	Coordenadas por prefixo de CEP, usadas na distância Haversine	☑ Sim
payment_type / payment_installments	Categórico / Numérico	Forma de pagamento e número de parcelas	☐ Não

---

5. ARQUITETURA E GOVERNANÇA

5.1 Representação do fluxo de dados (camadas):

Ingestão → Preparação → Armazenamento → Visualização

Ingestão: CSVs do Kaggle carregados no Google Colab/Databricks (Bronze). Preparação: limpeza, tipagem, joins e variáveis derivadas (Silver). Armazenamento: tabelas analíticas por vendedor, categoria e rota (Gold), versionadas no GitHub. Visualização: relatório executivo em PDF e/ou dashboard interativo.

5.2 Simulação de camadas de dados:

Camada	Formato / ferramenta usada	Exemplo de conteúdo
Raw	CSVs originais do Kaggle, sem alteração (Google Colab / Databricks; pasta data/bronze)	Os 9 arquivos da Olist exatamente como baixados
Trusted	Python (pandas) / Databricks; formato de armazenamento ainda a definir (Parquet ou Delta)	Datas convertidas, nulos e duplicados tratados, categorias traduzidas, geolocalização agregada por CEP e tabelas unidas (DataFrame mestre)
Curated	Python / Databricks; tabelas	Métricas por vendedor, benchmark por

Camada	Formato / ferramenta usada	Exemplo de conteúdo
	analíticas prontas para consumo	categoria, risco por rota e Nota de Saúde

5.3 Princípios de Governança aplicados:
☑ Catálogo de dados
☐ Políticas de acesso
☑ LGPD (simulado)
☐ Classificação de sensibilidade

---

6. ANÁLISE EXPLORATÓRIA

6.1 Técnicas utilizadas:
☑ Estatística descritiva
☑ Visualização gráfica
☐ Detecção de outliers
☑ Correlação entre variáveis
☐ Análise de sazonalidade / clusterização

☑ Outras: análise geográfica (distância Haversine) e análise de saturação por categoria e região

6.2 Ferramentas utilizadas:
☑ Python (Pandas / Seaborn / Matplotlib)
☐ R
☐ Power BI
☐ Tableau
☐ Google Looker Studio
☐ AutoML (especifique): _____

---

7. MODELAGEM PREDITIVA

7.1 Tipo de problema modelado:
☑ Classificação ☐ Regressão ☐ Agrupamento

7.2 Algoritmo(s) utilizados:
☐ Regressão Logística ☐ Árvore de Decisão ☐ K-Means ☑ Random Forest

☑ Outro: XGBoost

7.3 Métricas utilizadas para validação:
☐ Accuracy ☑ Precision ☑ Recall ☑ F1 Score ☐ MAE ☐ RMSE

---

8. DASHBOARD FINAL

8.1 Ferramenta utilizada:
☐ Power BI ☐ Tableau ☐ Looker Studio ☑ Outro: Streamlit (dashboard interativo) e relatório em PDF; ferramenta final a confirmar com o grupo

8.2 Público-alvo do dashboard:
☐ Diretoria ☑ Área de Negócio ☐ Stakeholders técnicos ☐ Equipe operacional

8.3 Principais KPIs apresentados:

KPI	Descrição	Valor atual	Meta ou insight
Nota de Saúde do E-commerce	Pontuação de 0 a 100 do vendedor frente aos melhores lojistas da categoria	A calcular (por vendedor)	Meta: aproximar o vendedor do benchmark da sua categoria
% de pedidos entregues com atraso	Pedidos entregues após a data estimada	8,1%	Pedidos atrasados têm nota média 2,57 contra 4,29 no prazo
Nota média de avaliação	Média do review_score dos pedidos entregues	4,16	Reduzir notas 1 e 2 (12,7% dos pedidos entregues)
Frete sobre preço	Mediana de freight_value ÷ price por item	23%	Itens com frete de 30% ou mais do preço: 37%
Tempo médio de entrega	Dias entre a compra e a entrega ao cliente	12,6 dias	Acima de 15 dias, as notas 1 aumentam de forma expressiva
Risco de atraso por rota	Probabilidade prevista de atraso (modelo) em verde, amarelo ou vermelho	A calcular (modelo)	Orientar a modalidade de envio e o prazo do anúncio

---

9. DOCUMENTAÇÃO E APRESENTAÇÃO FINAL

9.1 Repositório GitHub do projeto (link):

https://github.com/marialauramiran/projeto-final-mba-data-engineering

Trello: Projeto Simulador Vendedor Autonomo (MBA Data Engineering) | Trello

---

9.2 Componentes do repositório:

☑ README com visão geral

☑ Código-fonte (Python, SQL, etc.)

☑ Notebook técnico

☑ Slides de apresentação

☑ Artefatos complementares (ex: JSON, CSV, etc.)

9.3 Observações e aprendizados do grupo:

Destaque os desafios enfrentados, decisões importantes e o que aprenderam com o projeto.

Decisões: o escopo inicial (simulador de elasticidade de preço) foi substituído pelo Raio-X do Vendedor (Diagnóstico 360°) porque a base da Olist não traz dados de conversão nem variação controlada de preço; o simulador de margem, a análise de sentimento (NLP) e a Reforma Tributária ficaram como evolução futura. Desafios identificados: a maioria dos vendedores tem poucos pedidos, o que exige volume mínimo para formar o benchmark; apenas cerca de 8% dos pedidos atrasam, o que exige tratar o desbalanceamento de classes no modelo; a geolocalização tem 1 milhão de linhas com vários registros por CEP; e, por serem dados observacionais, as ações recomendadas indicam associação com os melhores lojistas, não garantem aumento de faturamento. Aprendizados: [o grupo complementa ao final do projeto].

Desenho inicial Arquitetura:

